Analyse des ventes d'un commerce de détail
version Tunisie

Projet Sales-Department-Project — rapport explicatif complet

Bienvenue : ce document explique chaque fichier du projet, les 8 étapes du notebook et tous les résultats obtenus.

Réseau fictif mais réaliste de 2 supérettes (Tunis et Sousse)
Ventes quotidiennes en dinars du 01/01/2022 au 31/12/2025
Machine Learning : modèle de prédiction des ventes

Document généré automatiquement — October 22, 2026

1. Objectifs du projet

Ce projet suit le standard d'un vrai travail de Data Scientist : partir d'un fichier de ventes brutes, le comprendre, le nettoyer, l'analyser, puis construire un modèle qui prédit l'avenir. Trois objectifs précis :

1. Analyser les **tendances** des ventes passées (croissance, saisons, week-ends) ;

2. Étudier l'impact de **facteurs externes** : jours fériés tunisiens, Ramadan, Aïd, prix du carburant ;

3. Construire un **modèle de Machine Learning** simple pour prédire les ventes du mois suivant.

2. Les données : ventes_tunisie_2022_2025.csv

Le dataset est **fictif mais réaliste** (généré avec un tirage aléatoire fixé, donc reproductible). Il simule les ventes d'un réseau de supérettes tunisiennes : 2 magasins, 1 461 jours (4 ans), soit 2 926 lignes :

Colonne	Signification
`Date`	le jour (AAAA-MM-JJ) ; 1 ligne = 1 magasin x 1 jour
`Magasin`	Supérette Tunis Centre-ville ou Supérette Sousse Marina
`Ventes_TND`	chiffre d'affaires du jour, en dinars tunisiens (TND)
`Jour_Ferie / Nom_Ferie`	0/1 et nom du férié : 17 décembre, Aïd, 1er mai, 25 juillet, Mouled, Ras-El-Am-Hejri...
`Ramadan`	0/1 : jour situé pendant le mois de jeûne (dates décalées chaque année)
`Prix_Carburant_TND`	prix de l'essence sans plomb (TND/litre), barèmes illustratifs

Le fichier contient **volontairement** des défauts pour rendre l'étape de nettoyage réaliste : 23 ventes manquantes, 4 doublons de saisie et 3 erreurs aberrantes (-650 ; -820 ; 260 000 TND). C'est exactement ce qu'on trouve dans les données d'entreprise.

3. Tous les fichiers du dossier et leur rôle

Fichier	Rôle dans le projet
`README.md`	Guide de démarrage : ouvrir le projet, résultats principaux, idées pour aller plus loin
`Sales_Department_Project.ipynb`	LE notebook pédagogique principal : 38 cellules (8 étapes), déjà exécuté, tout commenté pas à pas
`Sales_Department_Project.html`	La même documentation en une page web stylée : à ouvrir directement dans un navigateur
`Sales-Department-Rapport.pdf`	Ce rapport explicatif (le PDF que tu lis)
`ventes_tunisie_2022_2025.csv`	Le dataset de travail (entrée de tout le projet)
`generate_data.py`	Script Python qui génère le CSV : lance-le pour recréer les données à l'identique

Fichier	Rôle dans le projet
`build_notebook.py`	Script qui reconstruit le notebook (38 cellules) : utile si tu veux l'adapter
`build_rapport_pdf.py`	Script qui génère ce PDF
`figures/ (13 PNG)`	Les 13 graphiques importants du projet, sauvegardés par le notebook

4. Le notebook, étape par étape

Chaque étape a ses cellules de code commentées (chargement -> analyse -> modèle), plus des commentaires «que devons-nous apprendre ici ?» :

Étape 1 — Charger et découvrir les données. On lit le CSV avec pandas : df.head(), df.info(), df.describe(). Premiers réflexes d'un Data Scientist.

Étape 2 — Première exploration visuelle. La courbe des ventes et l'histogramme : on VOIT les pics (fériés, Ramadan) et on remarque les erreurs de saisie qui écrasent le graphique.

Étape 3 — Nettoyage. 4 doublons supprimés, ventes aberrantes transformées en «inconnu» puis comblées par interpolation magasin par magasin. Résultat : 0 trou.

Étape 4 — Tendances. Total du réseau + moyenne mobile 30 jours + chiffre d'affaires mensuel + heatmap semaine x mois : croissance, weekend du samedi, décembre et l'été touristique de Sousse apparents.

Étape 5 — Facteurs externes. Fériés : +27 % de ventes ; Ramadan : +27 % ; classement des fêtes ; corrélation gas et ventes faible et positive ($r \approx 0{,}23$), mais fallacieuse : les deux montent avec le TEMPS).

Étape 6 — Préparer le Machine Learning. 3 familles de variables : calendrier, mémoire (Ventes_J1, Ventes_J7, Moy_7j) et ancre de niveau (Base28 = moyenne des 28 jours passés). Découpage temporel : entraînement 2022-2024, test 2025.

Étape 7 — Deux forêts aléatoires. modele_demain (mémoire, spécialiste J+1) et modele_mois (ancre + calendrier, spécialiste du mois). Comparés à la référence naïve «demain = hier».

Étape 8 — Prévision de janvier 2026. Ancre figée (moyenne des 28 derniers jours réels) + forme du calendrier : prévision sans dérive.

5. Les résultats en un coup d'oeil

Question posée	Réponse trouvée
`Le réseau grandit-il ?`	+27 % de chiffre d'affaires entre 2022 et 2025 (+9 % par an environ)
`Le week-end aide-t-il ?`	Le samedi est le meilleur jour (vente moyenne la plus haute)
`Les fériés augmentent-ils les ventes ?`	Oui : +27 % en moyenne par rapport à un jour normal
`Effet du Ramadan ?`	+27 % (les courses des repas après le jeûne)

Question posée	Réponse trouvée
`Et le prix du carburant ?`	Corrélation faible et positive (r ≈ 0,23) : exemple de corrélation fallacieuse
`Qui prédit bien «demain» ?`	RF mémoire : MAE 2 112 TND contre 4 553 TND pour la naïve (-54 % d'erreurs)
`Que prévoit janvier 2026 ?`	846 902 TND (ancre figée pour éviter la dérive cumulative)

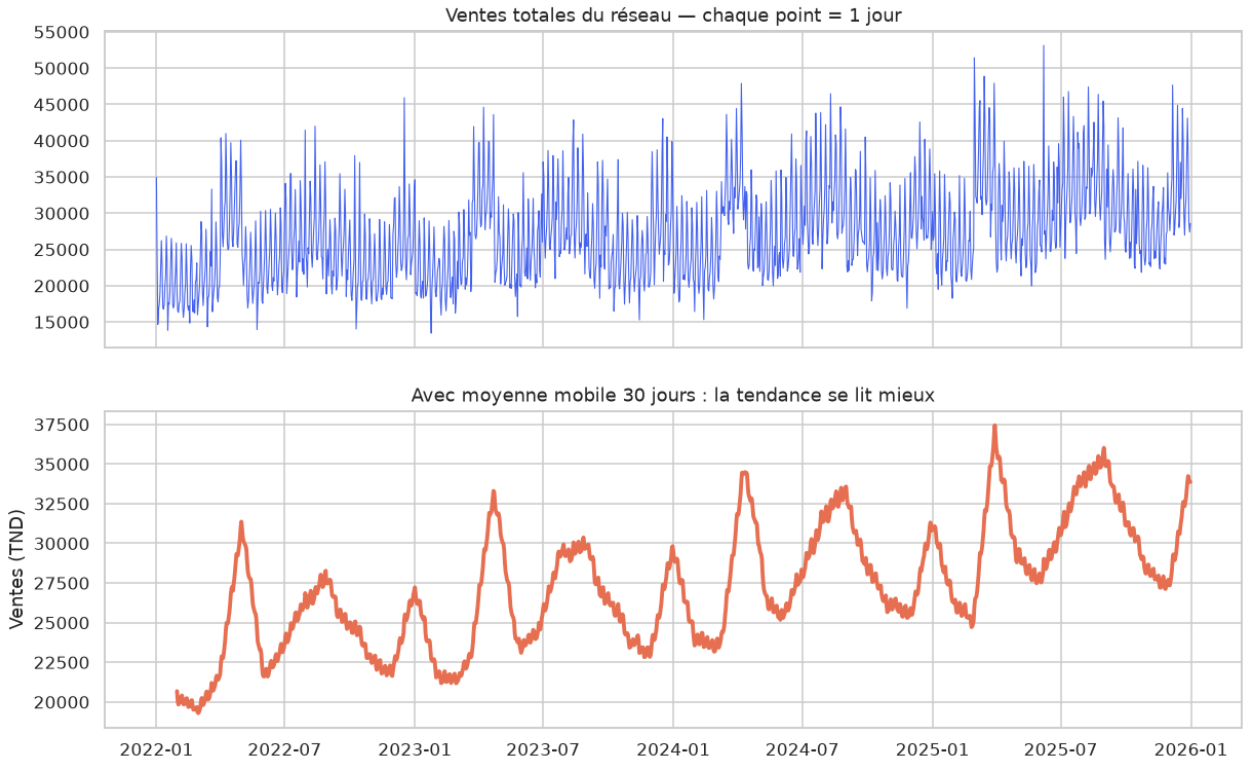


Figure 1 — Ventes du réseau : la courbe brute et la moyenne mobile 30 jours.

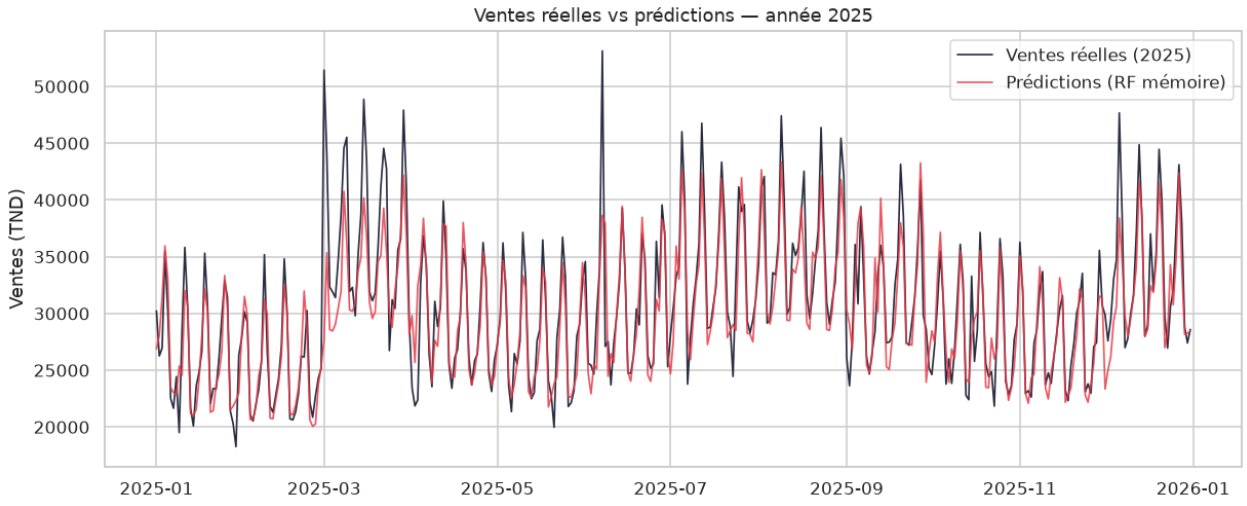


Figure 2 — Les prédictions (rouge) collent aux ventes réelles (noir) sur l'année test 2025.

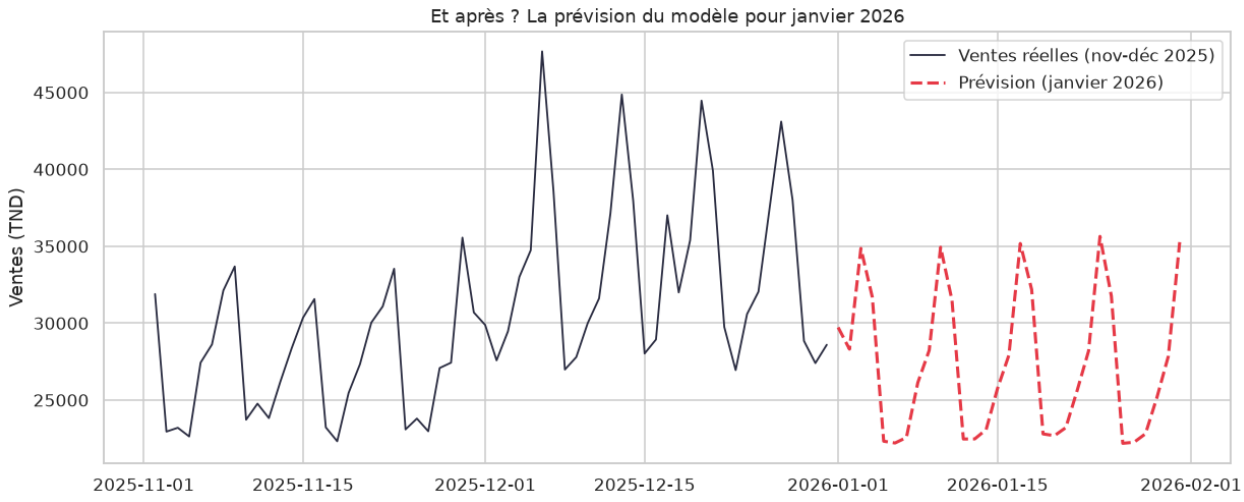


Figure 3 — La prévision (rouge en pointillés) de janvier 2026, sans dérive.

6. Comment utiliser le projet

Ouvrir une invite de commande (terminal) et entrer :

```
cd chemin/vers/Sales-Department-Project
jupyter notebook
```

Le navigateur s'ouvre : cliquer sur Sales_Department_Project.ipynb, puis exécuter une cellule avec Maj+Entrée, ou tout relancer via Kernel -> Restart & Run All. Sans terminal : double-cliquer sur Sales_Department_Project.html.

Tout est déjà installé sur cette machine (pandas, matplotlib, seaborn, scikit-learn, Jupyter) et le noyau Python 3 (Data Science) est enregistré.

7. Limites honnêtes et suites possibles

Limites : pas de météo dans les données ; hypothèse de prix du carburant stable ; le modèle «dans la moyenne» lisse un peu les extrêmes.

Pour aller plus loin : ajouter la température ; comparer avec Prophet ou XGBoost ; refaire un modèle par magasin ; créer une application Streamlit ; importer un vrai dataset Kaggle (ex. «Store Item Demand») avec la même démarche.

Mabrouk ! Bonne exploration des ventes !